

คำตอบคำถามนำ

จากไฟล์ 0_Reading Guide (อ่านก่อน).docx — ครบทั้ง 3 เฟส

สรุปนี้ generate โดย Claude จากการอ่านเปเปอร์ทั้งหมดใน 1_Foundation, 2_AI Landscape (DL+MLLM), และ 3_Gap+Method (Gou foil+UAV+eval) แล้วตอบ "คำถามนำ" ที่ระบุไว้ในตารางของ Reading Guide ที่ละข้อ ไม่ใช่ไฟล์ต้นฉบับ แก้ไข/สร้างใหม่ได้ตามปกติตาม rule_of_tune.md

เฟส 1 — Foundation (เข้าใจ domain)

รายละเอียดเต็ม + เกณฑ์ตัวเลขทั้งหมดอยู่ในไฟล์ "สรุปสาระสำคัญ เกณฑ์.pdf" ในโฟลเดอร์เดียวกัน — สรุปคำตอบสั้นๆ ที่นี้:

Q: routine / principal / special ต่างกันยังไง ใครตรวจ ความถี่เท่าไร

ประเภท	ลักษณะ	ความถี่
Routine (ปกติ)	ตรวจสอบสภาพทั่วไปด้วยสายตา	ทุก 1 ปี ถ้า OCR < 3 / ทุก 2 ปี ถ้า OCR ≥ 4
Principal (หลัก)	ตรวจสอบละเอียดกว่า ใกล้เคียงดีกว่า	ทุก 4 ปี ถ้า OCR ≤ 3 / ทุก 6 ปี ถ้า OCR ≥ 4
Special (พิเศษ)	เมื่อพบความเสียหายรุนแรง/สงสัยผิดปกติ ใช้ NDT/DT	ไม่มีรอบตายตัว เกิดตามเหตุการณ์

ที่มา: มาตรฐานไทย BMMS บทที่ 3 (cross-check กับรายงานวิจัย วช.68 บทที่ 2)

Q: condition states คืออะไร element weight มาจากไหน ประเภท+ระดับความเสียหาย

Condition state = BMMS 6 ระดับ (0-5) หรือ AASHTO 4 ระดับ (CS1-CS4) — ตัวเลขเกณฑ์เต็มอยู่ใน สรุปสาระสำคัญ เกณฑ์.pdf หัวข้อ 5 · Element weight มาจาก Pellegrino et al. (2011) ผูกกับรหัส AASHTO Element ID (คาน/เสา=10, พื้น/หมวกเสา=9, ดอม่อริม=8, ฐานราก=7, รอยต่อ/ผิวจราจร=6, ราว/ระบายน้ำ=5)

Q: Tier 1 / Tier 2 คืออะไร งานเราต่อยอดจากไหน

Tier 2 = งานรุ่นพี่ปีก่อน (3D Point Cloud framework, UAV+LiDAR+SLAM สร้าง digital twin) ช้าแต่แม่นยำ · Tier 1 = งานนี้ (คัดกรองเร็วจากภาพ 2D โดยตรง) เร็วแต่หยาบกว่า ใช้ flag สะพานที่ควรส่งไป Tier 2 ต่อ

เฟส 2 — AI Landscape (DL+MLLM)

Q1: วิธิตึม (CNN) ตรวจสอบความเสียหายยังงัย มีข้อจำกัดอะไร

(ที่มา: A systematic review of CNN-based structural condition assessment techniques — Sony et al. 2021)

วิธีตรวจ 3 แบบ: **Classification** (ทั้งภาพ เสียหาย/ไม่เสียหาย), **Localization** (กรอบ), **Segmentation** (pixel-wise) ใช้ **backbone** เช่น AlexNet/VGG/GoogleNet/ResNet และ **detector** อย่าง Faster R-CNN/SSD ตัวอย่างผล: AlexNet จำแนกสะพาน 96.6%, GoogleNet ตรวจรอยร้าว 99.36% (60,000 ภาพ), Narazaki: multiscale CNN แยกชิ้นส่วนจากสะพาน pixel-wise accuracy แต่ 78.94% "ขึ้นกับคุณภาพ super-pixel segmentation มาก"

ข้อจำกัด	รายละเอียด
1. Data imbalance	ข้อมูลความเสียหายหายาก/กระจายไม่สม่ำเสมอ โดยเฉพาะเหตุการณ์เสียหายรุนแรงที่หาภาพยาก
2. Generalization ข้ามโครงสร้าง	สะพานเหล็ก vs คอนกรีตยาวเท่ากัน อาจต้องใช้สถาปัตยกรรม CNN คนละแบบ ยังไม่มีมาตรฐาน scale ข้ามประเภทโครงสร้าง
3. ต้นทุนสูง	ต้องใช้ GPU/cloud/parallel processing ทำให้ operating cost สูง
4. ข้อมูลจริงรบกวนง่าย	เงา/แสง/ฝน/หมอก/วัตถุแปลกปลอม (เศษวัสดุ คน รถ) ทำ false positive — "ผลกระทบของสภาพอากาศ/แสง/ระยะกล้อง ยังไม่มีใครศึกษาในบริบท multiclass crack detection" (ตรงกับโจทย์ภาพโดรน T-BHI)
5. Multiclass = black box	ตรวจหลายประเภทพร้อมกันไม่ robust ต้อง track false-negative rate แยกจาก accuracy ไม่ใช่ดูแค่ accuracy เฉยๆ

Q2: multi-category damage detection ทำยังงัย (ตรวจหลายชนิด ไม่ใช่แค่รอยร้าว)

(ที่มา: Chen et al. 2023 — HSR RC bridge piers)

ใช้ AlexNet + Transfer Learning (freeze conv layers, fine-tune แค่ FC7/FC8) เทรนจากภาพทดสอบแผ่นดินไหวจริง แบ่งเป็น 3 กลุ่มหลัก (ไม่ทำละเอียดเกินไปเพราะข้อจำกัด): รอยร้าว, การกะเทาะ, เหล็กเสริมโผล่ + พื้นหลัง — 6,600 ตัวอย่างเทรน (1,300 ต่อคลาส + 2,700 พื้นหลัง)

ประเภท	Correct rate (ทดสอบจริง)	Recall
Concrete cracks	86.0%	84%
Reinforcement exposure	82.0%	73%
Concrete spalling	70.0%	69%
Background	98.0%	—

spalling อ่อนที่สุด (70%/69%) — ผู้เขียนอธิบายว่า "ความต่างระหว่างภาพเสียหายจริงที่จะตรวจกับตัวอย่างเทรน" ทำให้ accuracy จริงต่ำกว่าตอน validation (98%+) มาก บทเรียนสำหรับ T-BHI: อย่าเชื่อ validation accuracy สูงๆ จนกว่าจะทดสอบกับภาพภาคสนามจริง

Q3: จำแนกความเสียหายหลายชนิดในภาพเดียว + Grad-CAM

(ที่มา: Lateef & Yu 2026 — CODEBRIM dataset)

ใช้ Sigmoid (ไม่ใช่ Softmax) ที่ output layer ให้แต่ละคลาสทำนายอิสระต่อกัน (multi-label ไม่ใช่ single-label) เทรนด้วย binary cross-entropy บน CODEBRIM (7,729 ภาพ, 6 คลาส) เปรียบเทียบ VGG16/ResNet50/EfficientNetB0 — VGG16 fine-tuned ดีที่สุด: Subset Accuracy 84.0%, F1 85.2% (ดีกว่า benchmark เดิมทุกอัน)

ประเภทความเสียหาย	F1-score (VGG16)
Exposed Bars	0.894
Crack	0.879
Spalling	0.829
Efflorescence	0.830
Corrosion Stain	0.745 (อ่อนสุด)

Grad-CAM: ใช้ตรวจว่าโมเดลมองตรงจุดความเสียหายจริงหรือไม่ (คำนวณแยกทีละคลาส เพราะเป็น multi-label) ในเปเปอร์นี้แสดงผลเป็นเชิงยืนยัน (โมเดลมองถูกจุด) ไม่ได้โชว์ภาพ failure case ที่มองผิดจุดโดยตรง — แต่จาก recall ที่ตกของ Corrosion Stain ผู้เขียนสันนิษฐานว่าโมเดล "ให้ความสำคัญกับลักษณะ contrast สูง (กะเทาะ/เหล็กโผล่) มากกว่า จนกดความสำคัญของคราบสนิมที่จางกว่า" เวลาสองอย่างเกิดพร้อมกัน

Q4: MLLM คืออะไร ใช้ prompt + structured output ยังไง

(ความรู้ทั่วไป — ไม่ได้มาจากเปเปอร์เฉพาะในโปรเจกต์ ยังไม่มีไฟล์ InfraGPT/MLLM crack ในโปรเจกต์)

MLLM/VLM = LLM ที่รับภาพเป็น input ได้ด้วย (เช่น GPT-4o, Gemini, Claude, และรุ่น open-weight อย่าง LLaVA/Qwen-VL)
วิธี prompt ทั่วไป: ส่งภาพ+คำสังพร้อมกัน ระบุ schema JSON ที่ต้องการ (เช่น `{"defects":[{"type":...,"bbox":...,"severity":...}]}`) หลาย API รองรับ JSON-mode/function-calling บังคับ output ให้ตรง schema ได้เลย อาจใส่ few-shot example ช่วยด้วย — ข้อจำกัดที่ต้องรู้: MLLM ทั่วไปยังแม่นน้อยกว่าโมเดล detection เฉพาะทาง เรื่องกรอบ/mask ที่แม่นยำ และให้ severity ไม่ค่อยสม่ำเสมอซ้ำๆ กัน ควรใช้ประกอบกับโมเดล detection เฉพาะทาง ไม่ใช่ใช้เดี่ยวๆ เป็นแหล่งตัวเลขหลัก

เฟส 3 — Gap + Method (Gou foil+UAV+eval)

Q1: Spatial coding (foil) — link defect → ชิ้นส่วนยังงัย ทำไมต้องมี 3D ก่อน ทำไมเราเลือก "ไม่ใช่"

(ที่มา: Gou et al. 2026)

วิธีของเขา: จับคู่ defect กับชิ้นส่วนด้วยพิกัดล้วนๆ (ไม่ใช่เนื่อหาภาพ) — เช็คว่าพิกัด (ลองจิจูด/ละติจูด/ความสูง) ของ defect ตกอยู่ใน "กล่องขอบเขตเชิงพื้นที่" ของชิ้นส่วนไหน แต่ละชิ้นส่วนมีรหัสเฉพาะจาก ช่วง/ตำแหน่งตามยาว/ตามขวาง + พิกัดจุดเริ่ม-จบ-กึ่งกลาง

ทำไมต้องมี 3D ก่อน: "ถ้าไม่มีระบบพิกัดเชิงพื้นที่ ผู้ตรวจสอบต้องจับคู่ข้อมูลกับชิ้นส่วนที่ถูกต้องด้วยมือ ทำให้ช้า" — จำเป็นมากในระดับเครือข่าย (จีนมีสะพาน 1.1081 ล้านแห่ง) เพราะชิ้นส่วนที่หน้าตาเหมือนกัน (เสาต้นที่ 3 vs ต้นที่ 7) แยกไม่ออกด้วยภาพอย่างเดียว ต้องใช้พิกัดช่วยแยก

สิ่งที่เสียไปถ้าไม่ใช่ 3D (เหตุผลที่ต้องแลก): เสียการแยกแยะชิ้นส่วนหน้าตาเหมือนกันแบบอัตโนมัติ + เสีย ID ถาวรที่ track จุดเดิมซ้ำได้ข้ามรอบตรวจ — แต่แลกกับข้อดี: เปเปอร์เองยอมรับว่า "สัญญาณ GNSS

มักขาดหาย/เพี้ยนได้ท้องสะพานเพราะโครงสร้างบัง ทำให้พิกัดคลาดได้ตั้งแต่หลายสิบซม.ถึงมากกว่า 1 เมตร" — งาน 2D อย่าง T-BHI ไม่ต้องพึ่ง GNSS ได้สะพานเลย จึงไม่มีปัญหานี้ ภาระการระบุ "ชิ้นส่วนอะไร" จึงตกไปอยู่ที่ โมเดล YOLO segmentation ต้องรู้จำชิ้นส่วนจากรูปลักษณะในภาพแทนการ lookup พิกัด

Q2: Multi-stage system (Yasuno 2026) — ต่างจากเรายังงัย + location anonymization

Pipeline 5 ขั้นตอน: preprocess → SAM3 ตรวจความเสียหาย → DBSCAN เดิมจุดที่พลาต → ตรวจป้ายก่อสร้าง → เบลอป้องกันความเป็นส่วนตัว ผล: crack precision/recall 94.2%/91.8%, corrosion 96.1%/93.5%, F1 รวม 95.1%, เร็ว 1.7 วิ/ภาพ (RTX 4090)

มิติ	Yasuno 2026	T-BHI (เรา)
ตรวจชิ้นส่วนโครงสร้าง	ไม่มีเลย	มี (YOLO segmentation)
รวมคะแนนเป็น index	ไม่มี หยัดแค่ mask+เบลอ	มี (EHI/T-BHI formula)
Privacy/anonymization	มี (เบลอป้าย+k-anonymity)	ยังไม่มี

Location anonymization คืออะไร: ป้ายก่อสร้างในภาพมักบอกพิกัด/ชื่อสถานที่ เขาเบลอป้าย (Gaussian blur) + OCR ตรวจข้อความ + ใช้ k-anonymity ($k \geq 3$, ไม่ระบุที่ตั้งได้แค่มากกว่า 3 แห่งรวมกัน) เหตุผล:

"เพื่อให้ใช้งานโครงสร้างพื้นฐานได้อย่างปลอดภัยโดยไม่สร้างความกังวลสาธารณะ"

และป้องกันข้อมูลจุดอ่อนของโครงสร้างพื้นฐานสำคัญรั่วไหล ผล: ตรวจป้ายได้ 97.3%, คุ่มครองเนื้อหาอ่อนไหว 99.1%, ยังเก็บข้อมูลความเสียหายไว้ได้ 98.7% — ถ้า T-BHI จะเผยแพร่ภาพ/dataset สาธารณะในอนาคต ควรพิจารณาเรื่องนี้ด้วย แม้ยังไม่ใช่ requirement ตอนนี

Q3: จาก pixels → rating — ทำไมส่วนใหญ่หยุดที่ segmentation, gap อยู่ไหน

(ที่มา: Çelik et al. — เปเปอร์สำคัญที่สุดของเฟสนี้)

(a) Gap ที่ระบุตรงๆ: "งานส่วนใหญ่หยุดที่ semantic segmentation

มองข้ามขั้นตอนให้ระดับความเสียหายที่จำเป็นสำหรับงานตรวจสอบจริง" — "ยังไม่มี workflow ที่เชื่อม damage detection เข้ากับ BMS condition rating ได้อย่างสมบูรณ์" — นี่คือ gap เดียวกับที่ T-BHI กำลังแก้

(b) วิธีของเขา (ไม่ใช่สูตร pixel ตรงๆ แต่เป็น pipeline classify ข้อความ): Segmentation model (FPN+EfficientNet-B2) ให้ mask 8 ประเภทความเสียหาย → ใช้กฎซ้อนทับ mask หา compound damage (เช่น spalling∩corrosion = "spalling with exposed rebar") → เทียบกับลำดับความรุนแรง 12 อันดับที่กำหนดไว้ตายตัว เอาอันดับสูงสุดเป็น "damage type หลัก" → แปลงเป็นข้อความโครงสร้าง (element+damage+quantity) → ส่งเข้าBiLSTM 3 ตัวแยกกัน ทำนายคะแนน 0-4 สำหรับ Structural/Traffic/Durability แยกกัน (เลียนแบบขั้นตอนที่วิศวกรเยอรมันทำมือ: เทียบกับ ตัวอย่างความเสียหาย 1500+ กรณีที่มีอยู่แล้ว)

(c) ตัวเลขผล — ยืนยัน "20.6": Segmentation mean IoU = 20.6% (แม่นยำ 31.1%, recall 37.2%) ตรงกับที่ PROJECT_SUMMARY.md เคยอ้างไว้ — แย่สุดคือ honeycomb (IoU 2.1%, "เหมือนทรายแมว") ดีสุดคือ corrosion (26.8%) แต่ขั้นให้คะแนน (rating) กลับแม่นยำมาก: Traffic-safety F1 96.5%, Structural-stability F1 95.3%, Durability (อ่อนสุด) F1 71.5% — ข้อมูล 2,237,628 ระเบียบวินิบ กรองเหลือ 172,496 ตัวอย่างใช้เทรนได้จริง

(d) Human-in-the-loop: มีเต็มรูปแบบ — วิศวกรแก้ประเภทความเสียหายที่ทายผิดได้ก่อนคำนวณ ระบบแจ้งเตือนพิเศษเมื่อ คะแนนตกอยู่ในช่วงวิกฤต (durability 1-2, safety/stability 0-1) ให้ตรวจทานมือเสมอ และคะแนน 4 (ระดับปิดสะพาน) ถูกกันไว้ให้มนุษย์ตัดสินใจเท่านั้น ไม่ให้ AI ทำนายเลย — เป็นการออกแบบเพื่อความปลอดภัย ไม่ใช่แค่ข้อจำกัดข้อมูล

(e) เาไปใช้กับ T-BHI ได้:

- กฎ "เลือกความเสียหายหลักจากลำดับความรุนแรงตายตัว" — ใช้แทนการเฉลี่ยตรงๆ เวลาความเสียหายหลายชนิดซ้อนกัน
- กฎ mask-intersection หา compound damage — ไม่ต้องเทรนโมเดลเพิ่ม แค่ post-process
- Ordinal-aware loss (CE + ผลต่างระดับ) — ถ้า T-BHI เทรน classifier ให้ระดับความรุนแรงเอง ควรใช้ loss แบบนี้ เพราะระดับมีลำดับ ผิดใกล้ไม่เท่าผิดไกล
- Human-in-the-loop threshold + กันระดับวิกฤตสุดไม่ให้ AI ตัดสินเอง — pattern ด้านความปลอดภัยที่ควรลอกมาใช้
- ข้อจำกัดที่ห้ามลอก: วิธีจริงของเขาเป็นการเทรน BiLSTM จากข้อความ BMS 2.2 ล้านระเบียบขึ้นซึ่งไทยไม่มีข้อมูลระดับนี้ — T-BHI ต้องคิดสูตร/กฎเชิงตัวเลขเอง (ไม่ใช่ NLP classifier) โดยยืมแค่ "รูปแบบ" (segment → สักดกฎ → ให้คะแนน) ไม่ใช่ตัว implementation

คำถามที่ยังตอบไม่ได้ (ไม่มีไฟล์เปเปอร์ในโปรเจกต์)

Reading Guide สั่งให้โหลดเปเปอร์เพิ่มเองผ่าน VPN มก. — ยังไม่มีไฟล์เหล่านี้อยู่ในโปรเจกต์ จึงตอบคำถามที่ผูกกับมันไม่ได้:

- MLLM กับงานตรวจสอบจริง (มีใครใช้ MLLM กับ infrastructure/bridge แล้วบ้าง) — ต้องการ InfraGPT (arxiv.org/html/2510.16017v1) และ MLLM crack สะพานเหล็ก (ScienceDirect S0926580525000354, paywall)
- VLM hallucination (MLLM มั่ว/หลอนได้ไหม แก้อย่างไร) — ต้องการ VLM hallucination survey (arxiv.org/pdf/2507.19024)
- การประเมินระบบคัดกรอง (recall/precision, screening vs diagnostic) — Reading Guide เองระบุว่าข้อนี้เป็น "guided — ปรึกษาอาจารย์" ไม่ได้ผูกกับเปเปอร์เฉพาะ ควรถามอาจารย์ที่ปรึกษาโดยตรงตามที่ไฟล์แนะนำ

นอกจากนี้ยังมีไฟล์เดอร์ paper/ ที่ root โปรเจกต์ (แยกจากระบบ 3 เฟสนี้) 7 ไฟล์ที่ยังไม่ได้เปิดอ่าน อาจซ้ำหรือเป็นเปเปอร์เสริมอื่น ยังไม่ได้ตรวจสอบ